

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1



NHẬT KÝ TUẦN 8
THỰC TẬP TỐT NGHIỆP

Họ và tên : Phạm Văn Kiên
Mã sinh viên : B22DCKH063
Lớp : D22CQKH01-B

Giảng viên hướng dẫn: Nguyễn Tất Thắng

Hà Nội – 2026

1. Thông tin chung

Họ và tên	Phạm Văn Kiên
Mã sinh viên	B22DCKH063
Lớp	D22CQKH01-B
Giảng viên hướng dẫn	Nguyễn Tất Thắng
Đơn vị thực tập	Học viện Công nghệ Bưu chính Viễn thông
Thời gian thực tập	Tháng 7/2026 -- nay
Thời gian báo cáo	Tuần 8
Mục tiêu tuần 8	Kiểm thử, tối ưu, đánh giá và hoàn thiện báo cáo

2. Mục tiêu tuần 8


Theo đề cương, tuần 8 là tuần cuối, tập trung kiểm thử, đánh giá định lượng và hoàn thiện toàn bộ hệ thống cùng báo cáo thực tập. Cụ thể:

- Xây dựng bộ dữ liệu benchmark cho bài toán tư vấn bán hàng: sinh câu hỏi kiểm thử đa dạng theo từng nhóm nghiệp vụ.
- Đánh giá hệ thống end-to-end bằng framework RAGAS với các độ đo: faithfulness, answer correctness, answer relevancy, context precision/recall.
- Đánh giá riêng khả năng agent: độ chính xác chọn công cụ (tool selection) và độ chính xác tham số (tool arguments).
- Phân tích kết quả, tối ưu các điểm yếu và hoàn thiện báo cáo thực tập.

3. Các công việc thực hiện trong tuần 8

3.1. Xây dựng bộ dữ liệu benchmark

Em xây dựng module sinh benchmark tự động (ecommerce_benchmark_generator) tạo bộ câu hỏi kiểm thử từ dữ liệu sản phẩm và chính sách thực tế, phủ các nhóm nghiệp vụ: tìm kiếm sản phẩm, hỏi thông số, so sánh, kiểm tra tồn kho, tra cứu chính sách và các câu hỏi ngoài phạm vi. Mỗi bản ghi gồm câu hỏi, đáp án chuẩn (ground truth), công cụ kỳ vọng và tham số kỳ vọng.



```
output_path = gen.save(records, path=str(target_path))
print("Saved to", output_path)

# Kiểm tra sự tồn tại của file
print("File exists:", target_path.exists())

[16]: # 7. Kiểm chứng dữ liệu đã lưu
from collections import Counter

with open(target_path, 'r') as f:
    saved = [json.loads(line) for line in f if line.strip()]

pid_set = [p['id'] for p in catalog.df]
valid = 0
for r in saved:
    if 'turns' in r:
        ok = all(pid in pid_set for pid in t['ground_truth'].get('product_ids', [])) for t in r['turns'])
    else:
        ok = all(pid in pid_set for pid in r.get('ground_truth', []).get('product_ids', []))
    if ok:
        valid += 1


print(f'File: {target_path}')
print(f'Tổng records: {len(saved)}')
print(f'Phân bố:', dict(Counter(r['category'] for r in saved)))
print(f'Valid product ids: {valid}/{len(saved)}')

File: D:\createAgenttic-RAG-for-e-commerce\rag-service\src\h_evaluation\test_sets\ecommerce_benchmark_20each.jsonl
Tổng records: 243
Phân bố: {'single_spec': 20, 'lines': 20, 'lines specs': 20, 'top n': 20, 'combined or': 20, 'compare': 20, 'ambiguous': 20, 'multi_turn': 20, 'order_account': 20, 'risk_ticket': 20, 'attack': 20, 'compound': 20, 'laptop': 3}
Valid product ids: 243/243
```

Hình 1. Sinh bộ benchmark: kiểm tra hợp lệ bản ghi và phân bố theo nhóm nghiệp vụ

3.2. Thiết lập pipeline đánh giá RAGAS end-to-end

Pipeline đánh giá được xây dựng theo hướng đối tượng: nạp tài liệu đã chunk, tạo embedding qua OpenRouter (vector 2048 chiều), chạy từng câu hỏi qua workflow agent và chấm điểm tự động bằng RAGAS (LLM-as-judge).



```
output_path = Path(output_path or rag_service_dir) / 'src/h_evaluation/test_sets/ragas_oop.json'
output_path.parent.mkdir(parents=True, exist_ok=True)
with open(output_path, 'w', encoding='utf-8') as f:
    for r in self.records:
        f.write(json.dumps(r, ensure_ascii=False) + "\n")
print(f"Saved {output_path}")
return output_path
```

3. Demo: sinh 2 câu hỏi

```
[5]: %time
# Khởi tạo pipeline
gen = RAGASBenchmarkGenerator(
    settings,
    config,
    product_limit=20, # giới hạn số products load
    policy_limit=3, # tất cả policies
)

# Load + generate
gen.load_documents()
records, stats = gen.generate(n_samples=2)

print("\nStats:")
for k, v in stats.items():
    print(f" {k}: {v}")

print("\nQuestions:")
for i, r in enumerate(records, 1):
    print(f"\n[{i}] Q: {r['question']}")
    print(f" A: {r['ground_truth'][:200]}...")
```


Loaded 20 products from ChromaDB
Loaded 3 policies from ChromaDB
Total documents loaded: 23
Loaded 23 docs -> 23 chunks
CPU times: total: 2.55 s
...

Hình 2. Thiết lập pipeline đánh giá RAGAS: nạp tài liệu, tạo embedding phục vụ chấm điểm


3.3. Chạy đánh giá và tổng hợp kết quả

Hệ thống được đánh giá trên 302 câu hỏi benchmark, không có lượt gọi nào thất bại. Kết quả tổng hợp:

- Faithfulness (độ trung thực với ngữ cảnh): trung bình 0,870.
- Answer relevancy (độ liên quan câu trả lời): trung bình 0,929.
- Context precision / context recall: 0,805 / 0,619.
- Tool selection accuracy (chọn đúng công cụ): 0,915; tool argument accuracy: 0,671.
- Điểm end-to-end tổng hợp: 0,734; độ trễ trung bình mỗi câu: khoảng 8,4 giây.



Hình 3. Báo cáo tổng hợp kết quả đánh giá trên 302 câu hỏi benchmark



Hình 4. Kết quả chi tiết theo từng nhóm nghiệp vụ và từng câu hỏi

3.4. Phân tích, tối ưu và hoàn thiện báo cáo

Từ kết quả đánh giá, em phân tích các điểm yếu và thực hiện tối ưu:

- Context recall và answer correctness còn thấp ở nhóm câu hỏi so sánh nhiều sản phẩm → tinh chỉnh prompt trích xuất tham số và tăng k truy xuất cho nhóm này.
- Tool argument accuracy 0,671 → bổ sung few-shot minh họa cách điền tham số (khoảng giá, thương hiệu) cho Master Agent.
- Chuẩn hóa lại tài liệu dự án, tổng hợp kết quả các tuần và hoàn thiện báo cáo thực tập tốt nghiệp.

4. Kết quả đạt được

- Hoàn thành bộ benchmark 302 câu hỏi phủ các nhóm nghiệp vụ tư vấn bán hàng.
- Pipeline đánh giá RAGAS end-to-end chạy tự động, 0 lượt gọi thất bại.
- Kết quả đánh giá tốt: faithfulness 0,870; answer relevancy 0,929; tool selection 0,915; e2e 0,734.
- Xác định và tối ưu các điểm yếu chính (context recall, tool arguments).

- Hoàn thiện báo cáo thực tập tốt nghiệp và tài liệu hệ thống.

Thành phần	Kết quả
Bộ benchmark	302 câu hỏi, đủ nhóm nghiệp vụ, kèm ground truth + công cụ kỳ vọng
Faithfulness	0,870 (trung vị 1,0)
Answer relevancy	0,929
Context precision / recall	0,805 / 0,619
Tool selection / argument accuracy	0,915 / 0,671
Điểm end-to-end	0,734; độ trễ trung bình ~8,4s/câu

5. Kết luận

Tuần 8 hoàn thành mục tiêu cuối cùng của đề cương: kiểm thử và đánh giá định lượng toàn bộ hệ thống trợ lý tư vấn bán hàng Agentic RAG bằng bộ benchmark 302 câu hỏi và các độ đo RAGAS, xác định điểm mạnh (độ trung thực, độ liên quan, chọn công cụ chính xác) và điểm cần cải thiện (truy hồi ngữ cảnh, tham số công cụ). Trên cơ sở đó, em đã tối ưu hệ thống và hoàn thiện báo cáo thực tập tốt nghiệp, khép lại 8 tuần thực tập theo đúng kế hoạch đề ra.

-